# SCC0503 - Algoritmos e Estruturas de Dados II -Trabalho I - Árvore B

Guilherme Filipe Feitosa dos Santos NUSP: 11275092 Pedro Fernando Christofoletti dos Santos NUSP: 11218560

## Relatório:

Para realizar o trabalho de Árvore B e cumprir os requisitos solicitados organizamos o projeto em 5 arquivos:

# • Arquivo 1

"Main.c": Arquivo onde rodamos a aplicação, nele estamos criando e validando o arquivo de texto contendo os registros dos estudantes e o índice de árvore de B. Além disso, a main cuida do sistema de menu utilizando de um simples Switch para selecionar a opção desejada e também ao final da execução realiza o fechamento dos arquivos.

#### **Bibliotecas utilizadas:**

```
#include <stdio.h>
#include <stdlib.h>
#include "b_tree.h"
```

Criando e validando os arquivos de dados e da árvore:

```
FILE *data_file = fopen("dados.txt","a+b");
FILE *b_tree_index = fopen("index.dat","a+b");
if (checkFile(data_file))return 0;
if (checkFile(b_tree_index))return 0;
```

Menu para navegação:

```
do {
    printMenu();
    scanf("%d",&op);
    // system("clear");
    switch(op){
        case 1: { //Create data file and b tree
            b_tree_setup(data_file,b_tree_index);
            break;
        }
        case 2:{ //Insert
            b_tree_insertRegistry(data_file,b_tree_index);
            break;
        }
        case 3:{ //Search by USP number
            b_tree_searchRegistry(data_file, b_tree_index);
            break;
        }
    }
    while(op != 0);
```

### Fechando arquivos no final da execução:

```
closeFile(data_file);
closeFile(b_tree_index);
```

# Arquivo 2

"b\_tree.h": Arquivo de cabeçalho das funções contidas no arquivo "b\_tree.c", nesse cabeçalho são disponibilizadas apenas as funções que permitimos que o usuário acesse, no caso, a main. Além disso nele estão contidos os #defines e as structs. As funções possuem retornos de inteiros pois esses retornos são os próprios #defines, através desse retorno o usuário pode saber se a função obteve sucesso ou erro e o motivo do erro.

#### #defines:

```
#define SUCCESS 1
#define INVALID_FILE -1
#define INVALID_B_TREE_INDEX -2
#define RRN_NOT_FOUND -3
#define RRN_EXISTENT -4
#define EMPTY_FILE -5
```

\*Além desses, também há os defines para o tamanho das strings dos registros e de ordem da árvore:

```
#define SIZE 100
#define ORDER 170
```

## **Struct KEY e Struct B\_TREE\_NODE:**

```
typedef int keyType;

typedef struct {
   keyType NUSP; // 4 bytes
   long RRN; // 8 bytes
} KEY; // TOTAL = 16 bytes (A struct tambem ocupa espaco na memoria)

typedef struct {
   int counter; // 4 bytes
   KEY keys[ORDER-1]; // 16 * 169 = 2704 bytes
   long children[ORDER]; // 8 * 170 = 1360 bytes
} B_TREE_NODE; // TOTAL = 4079 bytes (A struct tambem ocupa espaco na memoria)
```

\*A ordem da árvore foi calculada com base no objetivo de chegar o mais próximo possível de uma página de disco de 4kb.

#### **Struct STUDENT:**

```
typedef struct {
  char name[SIZE];
  keyType numUSP;
  char lastname[SIZE];
  char course[SIZE];
  float grade;
} STUDENT;
```

Cabeçalho das funções disponibilizadas para main:

```
void printMenu();
void closeFile(FILE *);
int checkFile(FILE *);
int b_tree_setup(FILE *, FILE *);
int b_tree_insertRegistry(FILE *,FILE *);
int b_tree_searchRegistry(FILE *, FILE *);
```

# • Arquivo 3

"b\_tree.c": Arquivo onde estão implementadas tanto as funções do arquivo de cabeçalho quanto as funções auxiliares usadas apenas nesse arquivo e que não são disponibilizadas, essas funções auxiliares sempre começam com "\_\_" na frente do nome. As funções internas (\_\_) não requerem tratamentos ou retornos de erro pois são chamadas apenas pelas funções principais nas quais já são checados possíveis conflitos.

#### Bibliotecas utilizadas:

```
#include <stdio.h>
#include <stdlib.h>
#include <string.h>
#include <ctype.h>
#include <time.h>
#include "b_tree.h"
```

#### Menu:

\*A função irá printar o menu na tela e através do switch na main é possível escolher as opções desejadas. Existe uma função que garante que o usuário não registre ou procure antes de ter criado a árvore e o arquivo de dados. Segue a função:

Checa se já foram criados os arquivos da árvore e de dados e confere se já foram preenchidos:

```
// Check if b_tree and data file are filled with data
int __checkfilesize(FILE *file, FILE *b_tree_index){
   fseek(file, 0, SEEK_END);
   fseek(b_tree_index, 0, SEEK_END);
   if(ftell(file) == 0 && ftell(b_tree_index) == 0) return 1;
   else return 0;
}
```

\*Essa função vai até o final de cada arquivo e confere com o ftell se o ponteiro é igual a 0, se for igual a 0 quer dizer que o arquivo está vazio e a árvore ou arquivo de dados não foram criadas, caso contrário a função retornará 0 e permitirá a inserção ou busca.

Confere se o arquivo foi aberto e/ou criado com sucesso:

```
int checkFile(FILE *file){
   if(file == NULL){
      printf("ERROR, cannot open file");
      return 1;
   }
   return 0;
}
```

Cria e popula árvore e arquivo de dados:

```
int b_tree_setup(FILE *file, FILE *b_tree_index){
  if(!file) return INVALID_FILE;
if(!b_tree_index) return INVALID_B_TREE_INDEX;
  if(!_checkfilesize(file,b_tree_index)){
  printf("You have alredy set up the environment!\n");
  return SUCCESS;
 STUDENT student;
  long root_RRN;
 int i = 0, total;
KEY key;
 total = (ORDER / 2) * ORDER + 1; printf("Wait while the %d examples are loaded...\n n^*, total);
 fclose(b_tree_index);
b_tree_index = fopen("index.dat","rb+");
  _b_tree_create(b_tree_index);
  while(i < total){
   strcpy(student.name, __generateName(1));
strcpy(student.lastname, __generateName(1+1));
strcpy(student.course, __generateCourse(1));
student.grade = __generateGrade(1);
student.numUSP = 1;
     __printRegistry(student);
    //Inserting in file
fseek(file, 0, SEEK_END);
fwrite(&student,sizeof(STUDENT),1,file);
    key.NUSP = 1;
    key.RNR = 1;
fseek(b_tree_index, 0, SEEK_SET);
fread(&root_RRN, sizeof(long), 1, b_tree_index);
    _b_tree_insert(b_tree_index, key, root_RRN, NULL, 0);
  return SUCCESS;
```

\*A cada itereção do while um novo registro é adicionado tanto ao arquivo de dados quanto no arquivo da árvore B, o loop roda (ORDER / 2) \* ORDER + 1 vezes a fim de garantir que existam ao menos dois níveis na árvore.

Para gerar os dados foram utilizadas as seguintes funções:

**Gera nomes:** 

```
char * __generateName(int i){
    srand(time(NULL)+i);
    char consonants[21] = "bcdfghjklmnpqrstvwxyz";
    char vowels[5] = "aeiou";
    char *str = (char*) malloc(SIZE*sizeof(char));
    int pos=0;
    int syllables = (rand() % 3) + 2;
    for (int i=0;i<syllables;i++){
        str[pos] = consonants[(rand() % 21)];
        str[pos+1] = vowels[(rand() % 5)];
        pos+=2;
    }
    str[0] = toupper(str[0]);
    return str;
}</pre>
```

\*Essa função concatena uma consoante e uma vogal aleatoriamente utilizando da função rand com a seed setada para o clock do sistema somado ao número da iteração do loop a fim de garantir que não se repitam os nomes pois a função pode rodar mais de uma vez no mesmo segundo, ocasionando em uma seed igual, ou seja, o rand daria o mesmo resultado que o anterior. O nome pode variar entre 2 até 5 sílabas.

### **Gera cursos:**

```
char * __generateCourse(int i){
    char courses[7][100] = {"Bacharelado em Matematica","Licenciatura em Matematica","Bacharelado em Matematica Aplicada e
    Computacao Cientifica","Bacharelado em Ciencias de Computacao","Bacharelado em Sistemas de Informacao","Bacharelado em
    Estatistica e Ciencia da Dados","Engenharia de Computacao"};
    srand(time(NULL)+i);
    int pos = rand() % 7;
    char *str = (char*) malloc(SIZE*sizeof(char));
    strcpy(str,courses[pos]);
    return str;
}
```

\*Seguindo o mesmo princípio da aleatoriedade, essa função retorna um dos cursos armazenados em uma matriz de char que foi preenchida manualmente.

#### Gera notas:

```
float __generateGrade(int i){
    srand(time(NULL)+i);
    float grade = rand() % 11;
    return grade;
}
```

\*Novamente utilizamos a função rand para gerar uma nota de 0 a 10 para ser retornada.

OBS: Utilizamos a função gera nome tanto para o nome quanto sobrenome. Além disso, não criamos uma função para gerar o número usp pois ele está sendo gerado sequencialmente conforme a árvore e o arquivo de dados está sendo criado.

#### Printa um aluno:

```
void __printRegistry(STUDENT student){
  printf("\nName: %s\n",student.name);
  printf("Last Name: %s\n",student.lastname);
  printf("NUSP: %d\n",student.numUSP);
  printf("Course: %s\n",student.course);
  printf("Grade: %.2f\n\n",student.grade);
}
```

Função auxiliar interna para comparar dois inteiros:

```
int __compare(int a, int b){
  if (a==b) return 0;
  else if (a<b) return -1;
  else return 1;
}</pre>
```

Recebe e insere o registro de um aluno:

```
int b tree insertRegistry(FILE *file, FILE *b tree index){
 if(!file) return INVALID FILE;
 if(!b tree index) return INVALID B TREE INDEX;
 if( checkfilesize(file,b_tree_index)){
   printf("Please create file and B Tree before register or search\n");
   return EMPTY FILE;
 STUDENT student;
 printf("Name: ");scanf(" %[^\n]s",student.name);
 printf("Last Name: ");scanf(" %[^\n]s",student.lastname);
 printf("NUSP: ");scanf("%d",&student.numUSP);
 printf("Course: ");scanf(" %[^\n]s",student.course);
 printf("Grade: ");scanf("%f",&student.grade);
 KEY key:
 key.NUSP = student.numUSP;
 fseek(file, 0, SEEK_END);
 key.RRN = ftell(file) / sizeof(STUDENT);
 //Inserting in file
 fwrite(&student, sizeof(STUDENT), 1, file);
 long root_RRN;
 fseek(b_tree_index, 0, SEEK_SET);
 fread(&root_RRN, sizeof(long), 1, b tree index);
 //Inserting in B tree
 __b_tree_insert(b_tree_index, key, root_RRN, NULL, 0);
 printf("\nSuccessful registration!\n\n");
 return SUCCESS;
```

Busca um aluno pelo número NUSP:

```
int b tree searchRegistry(FILE *file, FILE *b tree index){
 if(!file) return INVALID FILE;
 if(!b tree index) return INVALID B TREE INDEX;
 if( checkfilesize(file,b tree index)){
   printf("Please create file and B Tree before register or search\n");
   return EMPTY_FILE;
 long root_RRN, byteoffset, RRN;
 STUDENT student;
 keyType nusp;
 printf("NUSP: ");scanf("%d",&nusp);
 printf("Searching...\n");
 fseek(b_tree_index, 0, SEEK_SET);
 fread(&root_RRN, sizeof(long), 1, b_tree_index);
 RRN = __b_tree_search(b_tree_index, root_RRN, nusp);
 if(RRN == RRN NOT FOUND){
   printf("NUSP not found\n\n");
 } else {
   byteoffset = RRN * sizeof(STUDENT);
   fseek(file, byteoffset, SEEK_SET);
   fread(&student, sizeof(student), 1, file);
    printRegistry(student);
  return SUCCESS;
```

\*O RRN é descoberto utilizando de uma função interna. Após descoberto posicionamos o ponteiro do arquivo de dados no lugar desejado, o registro é lido e em seguida printado na tela.

Função interna que descobre o RRN:

```
int _b_tree_search(FILE *b_tree_index, long RRN, int key){
 if (RRN == -1) return RRN NOT FOUND;
 else{
   int i = 0;
   B_TREE_NODE *node = (B_TREE_NODE *) malloc(sizeof(B_TREE_NODE));
   fseek(b_tree_index, ((sizeof(B_TREE_NODE) * RRN) + sizeof(long)), SEEK_SET);
   fread(node, sizeof(B_TREE_NODE), 1, b_tree_index);
   while(i<node->counter){
     int cmp = __compare(node->keys[i].NUSP, key);
     if(!cmp){
      return node->keys[i].RRN;
      } else if(cmp<0){ // key > node->keys->nusp
       i++;
      } else { // key < node->keys->nusp
       RRN = node->children[i];
       return __b_tree_search(b_tree_index, RRN, key);
   RRN = node->children[i];
   return __b_tree_search(b_tree_index, RRN, key);
```

\*Essa função começa lendo o primeiro nó da árvore inteiro (o RRN do primeiro nó foi disponibilizado através da leitura do cabeçalho de arquivo da árvore na função principal de busca). Após ler o primeiro nó, ela procura dentre todas as chaves do nó se alguma é igual ou maior que a chave passada pelo usuário, caso encontre alguma maior isso nos diz que aquela chave não está nesse nó e um novo nó é lido a partir do descendente da esquerda da primeira chave maior e o processo começa novamente, caso encontre uma chave igual é retornado o seu RRN, caso não encontre é porque chegou em algum nó folha com descendente -1.

### Função interna que esvazia nó a partir de uma posição:

Esta função usa seu parâmetro pos para inserir o sinal de -1 como forma de indicação de espaço vazio dentro de um node. Isso auxilia as outras funções a perceberem os espaços que estão vazios.

```
// Insere -1 nas posicoes a partir de pos
int _b_tree_empty_node_beginning_in_pos(B_TREE_NODE *node, int pos){
   if(!node) return INVALID_NODE;
   for(int i = pos; i < ORDER - 1; i++){
      node->keys[i].NUSP = -1;
      node->keys[i].RRN = -1;
      node->children[i+1] = -1;
   }
   if(pos == 0) node->children[0] = -1;
   return SUCCESS;
}
```

### Função auxiliar que insere uma key em uma posição do nó:

Diferente da função apresentada mais à frente que busca o nó folha onde a key deva ser inserida, esta função tem por objetivo encaixar a key exatamente na posição especificada. Para isso, a função verifica se o nó especificado está vazio, com espaço livro ou lotado, sendo neste último caso necessário realizar a manobra do split.

```
int _b tree put key in node(FILE *b tree index, B TREE MODE *node,
       long node RRN, KEY *key, long RRN, int pos, KEY **over key){
  long over RRN - 0;
  if(node->counter -- 0){ // No varie
   node->keys[8].NUSP = key->NUSP;
   node->keys[8].RRN = key->RRN;
   mode->children[0] - -1;
   node->counter = 1;
    _b tree_empty_node_beginning_in_pos(node, 1);
 *over key = MULL; // Monthema KEY precisara ser reposicionada
} else if(node->counter < (ORDER - 1)){ // No con espace
    memcpy(&node->keys[pos+1], &node->keys[pos], (node->counter - pos) * sizeof(KEY));
    mencpy(&node->children[pos+2], &node->children[pos+1], (node->counter - pos) * sizeof(long));
   node->keys[pos].NUSP = key->NUSP;
   node->keys[pos].RRN = key->RRN;
node->children[pos+1] = RRN;
    node->counter++:
   *over_key = MULL; // Nonhuma KEV precisara ser reposicionada
  } elso ( // Nó choic
    int new size = (ORDER - 1) / 2, i = 0, cmp;
    B_TREE_MODE *new_children, *to_insert;
```

```
new children = (8 TREE MODE *) calloc(1, sizeof(8 TREE MODE));
memove(new_children->keys, &node->keys[ORDER - 1 - new_size], new_size * sizeof(KEY));
memove(new_children->children, &node->children[ORDER - 1 - new_size], (new_size + 1) * sizeof(long));
mode-schildren[ORDER - 1 - new_size] = -1;
  b tree empty node beginning in pos(node, ORDER - 1 - new size);
_b tree_empty_node_beginning_in_pos(new_children, new_size);
new children->counter - new size;
node->counter -- new size;
if(pos < node->counter) to_insert = node;
 pos -= node->counter;
  to insert - new children;
memcpy(&to_insert->keys[pos+1], &to_insert->keys[pos],
 (to insert->counter - pos) * sizeof(KEY));
memcpy(&to_insert->children[pos+2], &to_insert->children[pos+1],
 (to insert->counter - pos) * sizeof(long));
to_insert->keys[pos].NUSP = key->NUSP;
to_insert->keys[pos].RRM = key->RRN;
to_insert->children[pos+1] = RRN;
to insert->counter++;
```

```
memcpy(&to insert->keys[pos+1], &to insert->keys[pos],
  (to_insert->counter - pos) * sizeof(KEY));
   memcpy(&to_insert->childrem[pos+2], &to_insert->childrem[pos+1],
(to_insert->counter - pos) * sizeof(long));
to_insert->keys[pos].NUSP = key->NUSP;
to_insert->keys[pos].NRN = key->NUSP;
   to_insert->children[pos+1] = RRN;
   to_insert->counter++;
   *ower_key = (KEY*) calloc(1, $1200F(KEY)); // Una KEV procisara sur reposicionada fseek(b_tree_index, 0, SEEK_END);
    over_RRN = (ftell(b_tree_index) - sizeof(long)) / sizeof(B_TREE_NODE);
   if(to_insert -- node){
      mammove(*over_key, &node->keys[node->counter - 1], sizeof(KEY));
node->keys[node->counter - 1].MUSP = -1;
node->keys[node->counter - 1].RRN = -1;
      node->children[node->counter] = -1;
      memove(*over key, &new_children->keys[0], sizeof(KEY));
memove(&new_children->keys[0], &new_children->keys[1], (new_children->counter - 1) * sizeof(KEY));
memove(&new_children->children[0], &new_children->children[1], (new_children->counter) * sizeof(KEY));
    to_insert->counter--;
   to_insert->keys[to_insert->counter].NUSP = -1;
to_insert->keys[to_insert->counter].RRM = -1;
   to insert->children[to insert->counter + 1] - -1;
  // Atualiza arquivo de indenacas
fwrite(new_children, sizeof(B_TREE_NODE), i, b_tree_index);
fseek(b_tree_index, ((sizeof(B_TREE_NOOE) * node_RRN) + sizeof(long)), SEEK_SET);
furite(node, sizeof(B_TREE_NODE), 1, b_tree_index);
return over_RRN;
```

## Função interna que cria novo nó e o define como root:

A seguinte função tem por objetivo facilitar a criação e definição no arquivo de um novo nó raiz. Isso pois essa ocorrência pode ser considerada como um caso à parte que deve ser tratado de uma maneira específica.

```
int __b_tree_new_root_node(FILE *b_tree_index, long left_RRN, long right_RRN, KEY *over_key){
    B_TREE_NODE *new_root;
    long root_RRN;

// Cria novo no raiz
    new_root = (B_TREE_NODE *) calloc(1, sizeof(B_TREE_NODE));

// Preenche novo no raiz
    new_root->keys[0].NUSP = over_key->NUSP;
    new_root->keys[0].RRN = over_key->RRN;
    new_root->children[0] = left_RRN;
    new_root->children[0] = right_RRN;
    new_root->counter = 1;
    _b_tree_empty_node_beginning_in_pos(new_root, 1);

// Insere_novo_no_raiz
    fseek(b_tree_index, 0, SEEK_END);
    root_RRN = (ftell(b_tree_index) - sizeof(long)) / sizeof(B_TREE_NODE);
    fwrite(new_root, sizeof(B_TREE_NODE), 1, b_tree_index);

// Atualiza_RRN_do_no_raiz_no_arquivo
    fseek(b_tree_index, 0, SEEK_SET);
    fwrite(&root_RRN, sizeof(long), 1, b_tree_index);

return_SUCCESS;
}
```

### Função interna que libera espaço alocado para over\_key auxiliar:

```
void __b_tree_free_over_key(KEY **over_key){
   free(over_key);
   free(*over_key);
}
```

### Função interna que descobre o RRN:

Função recursiva que percorre um nó verificando a posição relativa onde uma nova chave deve ser inserida. Possui algumas verificações auxiliares que a permitem identificar os possíveis cenários necessários para uma inserção, a citar quando uma chave é "promovida" dentro de um nó raiz que ficou cheio. Além disso, possibilita ao programa aproveitar a referência de posição encontrada para evitar processamentos e buscas repetidas.

```
int _b_tree_insert(FILE *b_tree_index, KEY key, long node_RRN, KEY **over_key, short level){
 if(over_key == NULL) { // Inicializa over_key auxiliar para primeira chamada da funcao recursiva
   over_key = (KEY **) malloc(sizeof(KEY*));
   *over_key = (KEY *) malloc(sizeof(KEY));
 long offset = ((sizeof(B_TREE_NODE) * node_RRN) + sizeof(long));
 B_TREE_NODE *node = (B_TREE_NODE *) calloc(1, sizeof(B_TREE_NODE));
  fseek(b_tree_index, offset, SEEK_SET);
  fread(node, sizeof(B_TREE_NODE), 1, b_tree_index);
 while(i<node->counter){
   int cmp = __compare(node->keys[1].NUSP, key.NUSP);
   if(cmp==0) return RRN_EXISTENT;
   else if(cmp<0) i++; // key > node->keys->nusp
   else if(cmp>0) break; // key < node->keys->nusp
  long over_RRN = -1;
  if(node->counter == 0 || node->children[i] == -1){ // No folha
   over_RRN = __b_tree_put_key_in_node(b_tree_index, node, node_RRN, &key, -1, i, over_key);
   if(over_RRN){ // Realizou split e promoveu alguma chave
     if(level == 0){ // No rais
       __b_tree_new_root_node(b_tree_index, node_RRN, over_RRN, *over_key);
       if(level == 0) __b_tree_free_over_key(over_key);
     if(level == 0) _b_tree_free_over_key(over_key);
     return over_RRN;
    if(level == 0) __b_tree_free_over_key(over_key);
   return 0;
  } else { // No "galho"
   over_RRN = __b_tree_insert(b_tree_index, key, node->children[i], over_key, level+1);
    if(over_RRN){ // Verifica se houve split no no seguinte
     memcpy(&key, *over_key, sizeof(KEY));
     over_RRN = __b_tree_put_key_in_node(b_tree_index, node, node_RRN, &key, over_RRN, i, over_key);
      1f(over_RRN && level == 0){ // No
       _b_tree_new_root_node(b_tree_index, node_RRN, over_RRN, *over_key);
       if(level == 0) __b_tree_free_over_key(over_key);
       return 0;
     if(level == 0) __b_tree_free_over_key(over_key);
     return over RRN:
   if(level == 0) _b_tree_free_over_key(over_key);
```

# • Arquivo 4

"dados.txt": Arquivo onde são armazenados os registros dos alunos, sempre um novo registro é adicionado ao final do arquivo e todos com tamanho fixo. O arquivo foi escrito de forma binária a fim de facilitar a implementação.

# • Arquivo 5

"index.dat": Arquivo onde é armazenada a Árvore B contendo cada nó uma página de disco de tamanho aproximado padrão 4Kb de memória. O arquivo foi escrito de forma binária a fim de facilitar a implementação.